

Clase 02 – Tipos de datos y gramática de los datos

Lenguaje de los Datos: Gobernanza, Visualización, Cultura e IA Generativa

Instituto Tecnológico José Mario Molina Pasquel y Henríquez
June 29, 2026

Agenda

Tipos de datos por su naturaleza

Estructurados, semi y no estructurados

Los datos y su representación

Gramática de los datos: tidy data

Malas prácticas en hojas de cálculo


Cuando Excel sale caro

Resumen

SECCION

Tipos de datos por su naturaleza

¿De qué tipo es un dato?



El **tipo** decide qué operaciones y graficas tienen sentido.

Datos cualitativos (categoricos)

- **Nominal**: categorias sin orden. Solo se pueden comparar por igualdad. Ej.: color de ojos, pais, tipo de sangre.
- **Ordinal**: categorias con un orden, pero sin distancia definida. Ej.: nivel educativo, satisfaccion (bajo/medio/alto), severidad.
- **Binario / booleano**: caso especial con dos categorias (si/no, verdadero/falso, 0/1).

Cuidado

Codificar “bajo=1, medio=2, alto=3” NO los vuelve numeros: la diferencia entre niveles no es comparable como en una escala continua.

Datos cuantitativos (numericos)

- **Discreto:** valores contables, normalmente enteros. Ej.: numero de hijos, visitas a una pagina, defectos por lote.
- **Continuo:** cualquier valor en un intervalo (se mide). Ej.: estatura, temperatura, tiempo de respuesta.

Escalas de medicion clasicas (Stevens):

- **Intervalo:** sin cero absoluto (grados Celsius, año).
- **Razon:** con cero absoluto (peso, ingreso, distancia).

Tipos especiales: fechas, tiempo y texto

- **Fecha / hora:** parecen texto, pero tienen orden y aritmetica (restar fechas da una duración). Usar siempre formato ISO 8601: 2026-06-29, no 29/06/26.
- **Series de tiempo:** secuencia de valores indexada por instante.
- **Geoespacial:** coordenadas (lat, lon), poligonos.
- **Texto libre:** cadena sin estructura fija (un comentario, un articulo) – es el puente hacia los datos no estructurados.

SECCION

Estructurados, semi y no estructurados

Tres grandes familias por su estructura

Estructurados

filas y columnas
esquema fijo
tablas SQL,
CSV, hojas

Semi-estructurados

etiquetas/jerarquia
esquema flexible
JSON, XML,
YAML, logs

No estructurados

sin esquema tabular
texto, imagen,
audio, video

Se estima que el **80-90%** de los datos del mundo son no estructurados: ahí es donde el deep learning y los LLM aportan más.

El mismo hecho en tres formatos

Estructurado (tabla)

id	nombre	edad
1	Ana	34
2	Luis	29

Semi-estructurado (JSON)

```
{"id":1,"nombre":"Ana",  
  "edad":34,  
  "hobbies":["correr"]}
```

No estructurado (texto)

```
"Ana, de 34 años, sale  
a correr cada mañana  
antes del trabajo."
```

A más estructura, más fácil de consultar; a menos estructura, más riqueza y más trabajo de preparación.

SECCION

Los datos y su representación


Al final, todo se vuelve numeros

Para que una computadora (y un modelo) procese un dato, hay que **representarlo** como numeros:

- **Tabla:** matriz filas x columnas.
- **Imagen:** matriz de pixeles (alto x ancho x canales RGB).
- **Audio:** vector de amplitudes muestreadas en el tiempo.
- **Texto:** secuencia de tokens -> vectores (embeddings).
- **Grafo:** nodos + aristas (matriz de adyacencia).

La representación elegida condiciona qué modelo se puede usar.

Una imagen es una matriz de pixeles




- Cada celda es un **pixel**: un numero 0–255 por canal.
- Gris: una matriz $H \times W$. Color: tres matrices (R, G, B).
- Una foto de 640x640 a color son $640 \cdot 640 \cdot 3 \approx 1.2$ millones de numeros.

Por eso las imágenes son “pesadas” y necesitan redes especializadas (CNN).

Tablas, grafos, audio y texto

Grafo (nodos + aristas)



Audio (forma de onda)



Amplitud muestreada (p.ej. 44100 Hz).

Redes sociales, mapas, moléculas.

Texto: “el gato” -> tokens [e1] [gato] -> vectores numéricos (embeddings) que capturan significado.

SECCION

Gramática de los datos: tidy data

¿Qué es la gramática de los datos?

Así como una lengua tiene reglas para formar frases claras, los datos tabulares tienen una **gramática** para ser ordenados y reutilizables. El estándar es *tidy data* (Hadley Wickham):

1. Cada **variable** es una **columna**.
2. Cada **observación** es una **fila**.
3. Cada **tipo de unidad observacional** es una **tabla**.

Por que importa

Datos ordenados = una sola forma correcta; datos desordenados = mil formas distintas. Lo ordenado se filtra, agrupa y grafica sin pelear.

Formato ancho (wide) vs ordenado (tidy)

Wide (años como columnas)

ciudad		2020		2021		2022
GDL		28.1		28.7		29.0
CDMX		17.5		17.9		18.2

Comodo para leer, malo para procesar: el año es un **valor**, no una variable.

Tidy (una observacion por fila)

ciudad		anio		temp
GDL		2020		28.1
GDL		2021		28.7
GDL		2022		29.0
CDMX		2020		17.5
...				

De wide a tidy con pandas

```
import pandas as pd

# wide: una columna por año
df = pd.read_csv("temperaturas_wide.csv")

# melt: "alarga" la tabla a formato tidy
tidy = df.melt(id_vars="ciudad",
               var_name="año",
               value_name="temp")

tidy["año"] = tidy["año"].astype(int)
```

melt ordena (wide -> long); pivot hace lo inverso (long -> wide) cuando se necesita una tabla de reporte.

SECCION

Malas prácticas en hojas de cálculo

Reglas de oro para una tabla sana

Si

- Una variable por columna.
- Una observación por fila.
- Encabezados en la 1a fila, cortos y sin espacios.
- Un solo dato por celda.
- Codigos de faltante explicitos (NA).

No

- Celdas combinadas (merge).
- Colores como si fueran datos.
- Varias tablas en una hoja.
- Totales mezclados con datos.
- Unidades dentro de la celda ("34 kg").

Malas practicas tipicas (y su arreglo)

- **Columnas que inician con numero o espacio:** 2020, 1er trimestre. Muchas herramientas no las aceptan como nombre. Arreglo: `anio_2020`, `trim_1`.
- **Los datos crecen en filas, no en columnas:** agregar un año nuevo NO debe ser una columna nueva, sino filas nuevas (formato tidy).
- **Fechas como texto** (29/06/26): ambiguas y no ordenables. Arreglo: ISO 2026-06-29.
- **Nombres que el programa “corrige” solo:** ver el caso de los genes en la siguiente sección.

SECCION

Cuando Excel sale caro

Catastrofes reales por hojas de calculo (I)

Reinhart & Rogoff (2010)

Un paper muy citado sobre deuda y crecimiento tenía un rango de celdas mal seleccionado en Excel: omitió 5 países. El error reforzó políticas de **austeridad** antes de ser detectado por un estudiante en 2013.

Public Health England (2020)

Cerca de **16,000 casos de COVID-19** no se reportaron porque se uso el formato viejo .xls, limitado a 65,536 filas: los contagios extra simplemente se truncaron y no se rastrearon contactos.

Catastrofes reales por hojas de calculo (II)

- **Genes convertidos en fechas:** Excel transformaba SEPT2 en “2-Sep” y MARCH1 en fecha. Un estudio (2016) halló errores en **1 de cada 5** papers genomicos; en 2020 el comite HGNC **renombro genes** para esquivar a Excel.
- **JPMorgan “London Whale” (2012):** un modelo de riesgo en Excel con copiar/pegar manual entre celdas contribuyo a perdidas de **6 mil millones** de dolares.
- **TransAlta (2003):** un error de copiar/pegar en una hoja le costo **24 millones** de dolares en contratos mal asignados.

Moraleja: la hoja de calculo es genial para mirar, peligrosa como base de datos.

SECCION

Resumen

Takeaways

- Los datos se clasifican por **naturaleza** (cualitativos vs cuantitativos; nominal/ordinal, discreto/continuo) y por **estructura** (estructurados, semi, no estructurados).
- Todo dato – imagen, audio, texto, grafo – termina representado como **numeros**; la representación define el modelo aplicable.
- La **gramatica tidy**: una variable por columna, una observación por fila, una tabla por unidad.
- Las hojas de calculo invitan a malas prácticas; varios desastres (Reinhart-Rogoff, PHE, genes, JPMorgan) nacieron de ahí.
- Datos ordenados hoy = menos sufrimiento (y menos catastrofes) mañana.

Gracias

Siguiente: limpieza y preparación de datos en la práctica