

Clase 03 – Ciclo de vida de los datos (Parte I)

Creación y captura; Transmisión y almacenamiento

Instituto Tecnológico José Mario Molina Pasquel y Henríquez
June 29, 2026

Agenda

El ciclo de vida de los datos

Etapas 01: Creación y captura

Etapas 02: Transmisión y almacenamiento

Resumen

SECCION

El ciclo de vida de los datos

El ciclo de vida de los datos



Describe las fases por las que pasan los datos desde su creación hasta su eliminación o archivado.

En esta clase (Parte I)

Vemos a detalle las etapas **01 Creación y captura** y **02 Transmisión y almacenamiento**.

SECCION

Etapa 01: Creación y captura

Creación y captura: definición y errores


Definición

Generación u obtención de datos: sensores, formularios, transacciones, APIs, etc.

Posibles errores

- Datos incompletos (campos vacíos).
- Datos duplicados.
- Errores de formato (fecha como texto: “12/31/2024” vs “31-12-2024”).
- Sesgo en la recolección (muestras no representativas).
- Codificación distinta (UTF-8).

¿Cómo se capturan los datos?



Cada método tiene un costo, una cobertura y un nivel de error distintos.

Recopilación **sistemática y exhaustiva** de datos de **toda la población** de interés (no solo una muestra).

- Busca datos completos, no inferidos.
- La metodología determina el nivel de confianza y error.

Retos

- Alto costo (recursos, logística, tiempo).
- Cobertura completa (zonas remotas).
- Actualización (se vuelve obsoleto).
- Participación (resistencia a responder).

El censo es un proceso mayor

Etapas típicas

1. Objetivos y alcance.
2. Marco legal y financiamiento.
3. Diseño metodológico.
4. Prueba piloto.
5. Recolección y monitoreo.
6. Procesamiento y validación.
7. Difusión y evaluación.

Tipos de censo

- Población y vivienda (cada 10 años).
- Económicos (cada 5 años).
- Agropecuario (cada 10 años).
- De gobierno (anual / bienal).

En México: el INEGI (creado en 1983) levanta el Censo de Población y Vivienda; en 2020 conto 126 millones de personas.

Encuesta

Recolección mediante cuestionarios aplicados a una **muestra representativa** para *inferir* sobre toda la población.

- Muestra aleatoria; se buscan tendencias generales.
- El margen de error es aceptable y conocido.

Confianza del 95%, error $\pm 3\%$

Si se repitiera el estudio 100 veces, en 95 los resultados caerían dentro del margen. **No** garantiza exactitud: hay 95% de probabilidad de estar cerca de lo real.

Retos

- Diseño del cuestionario (preguntas sesgadas).
- Tasa de respuesta (no respuesta).
- Sesgos (deseabilidad social).
- Costo en muestras grandes.

Otros métodos de captura

Sondeo

Rápido y **no exhaustivo**; visión preliminar. Más errores y sesgos; resultados **no generalizables**.

Sensores

Medición **directa o indirecta** y monitoreo continuo. Retos: costo y acceso (privacidad).

Datos administrativos

Recolectados para fines **no estadísticos** (salud, impuestos). Retos: calidad inconsistente y acceso restringido.

Levantamiento en campo

Recolección **in situ** (observación, mediciones). Retos: accesibilidad, precisión, clima, logística.

Minería de datos y Big Data: las 5 V



Big data: colecciones enormes y diversas (estructuradas, semi y no estructuradas) que crecen y que los sistemas tradicionales no pueden almacenar/procesar. **Minería de datos:** analizar esos grandes volúmenes para hallar patrones.

Técnicas: MapReduce, cómputo paralelo y muestreo (sampling).

Fuentes de datos abiertos

Muchos datos ya estan creados y disponibles para reutilizarse:

- **México:** datos.gob.mx, iiieg.gob.mx
- **EE.UU.:** [Data.gov](https://data.gov)
- **Unión Europea:** [European Data Portal](https://european-data-portal.eu)
- **Reino Unido:** data.gov.uk
- **NASA:** [Open Data Portal](https://open.data.nasa.gov)
- **NOAA / ESA:** clima e imágenes satelitales
- **Kaggle, DrivenData:** datasets

Antes de capturar datos nuevos, conviene revisar si ya existen.

SECCION

Etapa 02: Transmisión y almacenamiento

Transmisión y almacenamiento: definición y errores

Definición

Los datos se envían y guardan en bases de datos, *data lakes* o *data warehouses* para su uso posterior.

Posibles errores

- Pérdida por fallos de hardware.
- Almacenamiento redundante / duplicidad.
- Estructura inadecuada (tablas mal normalizadas).
- Sin respaldo (regla 3-2-1) o respaldos no periódicos.
- Corrupción de datos; errores en el ETL.
- Formatos incompatibles.

Buena práctica de respaldo: la regla 3-2-1

3

copias de
los datos

2

tipos de
medios distintos

1

copia fuera
del sitio

Mantener **tres** copias de los datos, en **dos** tipos de medios y con **una** copia fuera del sitio reduce el riesgo de perderlo todo.

ETL: Extract – Transform – Load



El ETL mueve los datos desde las fuentes hacia el siguiente proceso (“el plomero de los datos”): **Extract** obtiene, **Transform** limpia y calcula, **Load** carga en el repositorio destino.

¿Dónde se guardan? Lake, Warehouse y Lakehouse

Data Lake

Repositorio de datos **en bruto** (estructurados, semi y no estructurados), esquema flexible (*schema-on-read*), escalable (Hadoop, AWS S3).

Data Warehouse


Repositorio **centralizado** de datos estructurados y **procesados** (ETL), esquema fijo (*schema-on-write*), orientado a consultas y reportes (Snowflake, BigQuery).

El **Data Lakehouse** combina ambos: la flexibilidad del lake con una capa de gobierno y metadatos para analítica y ML.

Data Warehouse vs Data Lake

Aspecto	Data Warehouse	Data Lake
Tipo de datos	Solo estructurados (SQL)	Cualquier tipo (JSON, imágenes, logs)
Procesamiento	Transformados antes (ETL)	En crudo (se procesan al leer)
Esquema	<i>schema-on-write</i>	<i>schema-on-read</i>
Usuarios	Analistas de BI	Científicos de datos / ingenieros
Herramientas	Snowflake, Redshift, Big-Query	Hadoop, AWS S3, Azure Data Lake

La tubería de datos (data pipeline)



Una arquitectura de datos encadena estas etapas; debajo, una capa transversal de gobierno vigila calidad, privacidad y seguridad.

Orquestación de datos


Es el proceso de **extraer datos aislados** de múltiples ubicaciones, combinarlos, organizarlos y ponerlos a disposición del análisis. Incluye aprovisionar recursos y **monitorear**.

- Automatiza pipelines ETL/ELT que corren solos y se reintentan.
- Disparadores: por horario, por evento o por dependencia.

Herramientas

- Apache Airflow
- Luigi (Spotify)
- Oozie, Azkaban
- Control-M, AutoSys

Apache Airflow



Un **DAG**: tareas ordenadas sin ciclos.

Plataforma open-source (en Python) para **orquestrar workflows**.

- **DAG**: grafo acíclico dirigido de tareas.
- **Operators**: bloques (PythonOperator, BashOperator).
- **Tasks**: instancias de un operator.
- **Scheduler**: ejecuta según dependencias.
- **Executor**: define cómo corren (Local, Celery).

Un DAG minimo en Airflow

```
from airflow import DAG
from airflow.operators.python import PythonOperator
import datetime as dt

with DAG("etl_diario", schedule="@daily",
        start_date=dt.datetime(2026, 1, 1)) as dag:

    extraer = PythonOperator(task_id="extraer", python_callable=extract)
    limpiar = PythonOperator(task_id="limpiar", python_callable=transform)
    cargar = PythonOperator(task_id="cargar", python_callable=load)

    extraer >> limpiar >> cargar    # define el orden
```

El operador » fija las dependencias: primero extraer, luego limpiar, luego cargar.

SECCION

Resumen

Takeaways

- El **ciclo de vida** va de la creación al archivado; hoy vimos **captura** y **almacenamiento**.
- La **captura** tiene muchos métodos (censo, encuesta, sondeo, sensores, big data); cada uno con su costo, cobertura y error.
- Una **encuesta** infiere de una muestra: confianza del 95% no es exactitud, sino probabilidad de estar cerca.
- En **almacenamiento**, respaldar con la regla **3-2-1** y mover datos con **ETL**.
- **Data Lake** (crudo, flexible) vs **Data Warehouse** (estructurado, ETL); el **Lakehouse** combina ambos.
- La **orquestación** (Airflow y sus DAGs) automatiza y vigila los pipelines.

Gracias

Siguiente (Parte II): acceso y seguridad; limpieza, análisis y visualización