

Clase 04 – Ciclo de vida de los datos (Parte II)

Acceso y seguridad; Limpieza, análisis y visualización; Archivado y eliminación

Instituto Tecnológico José Mario Molina Pasquel y Henríquez
June 29, 2026

Agenda

El ciclo de vida: etapas 03, 04 y 05

Etapas 03: Gestión de acceso y seguridad

Etapas 04: Limpieza, análisis y visualización

Etapas 05: Archivado y eliminación

Resumen

SECCION

El ciclo de vida: etapas 03, 04 y 05

Donde estamos en el ciclo de vida



En la Parte I vimos captura y almacenamiento.

En esta clase (Parte II)

03 Gestión de acceso y seguridad.

04 Limpieza, uso, análisis y visualización.

05 Archivado y eliminación.

SECCION

Etapa 03: Gestión de acceso y seguridad

Acceso y seguridad: definición y errores

Definición

Los datos se comparten con otros usuarios y fluyen a otras aplicaciones; hay que protegerlos en el camino.

Posibles errores

- Robo o secuestro de datos (ransomware).
- Datos inaccesibles; formatos obsoletos.
- Riesgos legales.
- Falta de encriptación o anonimización.
- No cumplir con estándares.

Ciberseguridad y amenazas potenciadas por IA

Ciberseguridad: prácticas y principios para proteger sistemas y datos contra ataques digitales.

La IA como amenaza

- Ingeniería social (phishing).
- **Deepfakes** (audio/video falsos).
- **Data poisoning** (envenenar el entrenamiento).
- Password hacking acelerado.

La IA como defensa

- Detección de fraude y phishing.
- Seguridad de red; detección más rápida.
- Autenticación segura.
- Behavioral analytics.

Riesgos en bases de datos y procesos ETL

Riesgo	Bases de datos	Procesos ETL
Inyección	SQL Injection	Inyección en transformaciones
Exposición	Datos en reposo	Datos en tránsito
Autenticación	Privilegios excesivos	Credenciales en código
Integridad	Corrupción de datos	Datos no validados

Los datos se exponen en dos momentos: **en reposo** (guardados) y **en tránsito** (mientras viajan). Ambos deben cifrarse.

Buenas prácticas de seguridad

- **Inyección SQL:** usar *consultas parametrizadas* y validar/sanitizar las entradas.
- **Cifrado:** en reposo (AES-256) y en tránsito (TLS).
- **Mínimos privilegios** (*RBAC*, Role-Based Access Control): cada usuario solo accede a lo que necesita.
- **Hardening:** deshabilitar servicios y puertos innecesarios, cambiar credenciales por defecto.
- **Backups** automáticos y encriptados, y **probarlos**.

Inyección SQL: el ejemplo clasico

```
# MAL: concatenar la entrada del usuario en la consulta
usuario = input()                # p.ej.: ' OR '1'='1
q = "SELECT * FROM users WHERE name = '" + usuario + "'"
cur.execute(q)                   # un atacante puede leer toda la tabla

# BIEN: consulta parametrizada (la entrada nunca es codigo)
cur.execute("SELECT * FROM users WHERE name = ?", (usuario,))
```

La consulta parametrizada trata la entrada como **dato**, nunca como parte del comando SQL.

SECCION

Etapa 04: Limpieza, análisis y visualización

Limpieza y análisis: definición y errores

Definición

Los datos se depuran y procesan para calcular, analizar o visualizar algo.

Taller de datos

Ordenar (tidy), buscar faltantes, describir y transformar tipos, visualizar y resolver problemas.

Posibles errores

- Uso de datos desactualizados.
- Interpretación incorrecta.
- Falta de revisión de los procedimientos.

Análisis exploratorio de datos (EDA)

**Análisis
descriptivo**

**Tipos de
variables**

**Datos
faltantes**

**Outliers
(atípicos)**

**Correlación
de variables**

El **EDA** transforma datos en crudo en conclusiones: describe la distribución, ajusta tipos, trata faltantes, detecta atípicos y mide relaciones. Para muchas variables se usa **reducción de dimensionalidad** (PCA, t-SNE, UMAP).

Detectar outliers con el rango intercuartil (IQR)

```
q1 = df["ingreso"].quantile(0.25)
q3 = df["ingreso"].quantile(0.75)
iqr = q3 - q1
bajo, alto = q1 - 1.5 * iqr, q3 + 1.5 * iqr

# valores fuera de [bajo, alto] son atipicos
atipicos = df[(df["ingreso"] < bajo) | (df["ingreso"] > alto)]
```


La regla **1.5 x IQR** marca como atípicos los valores muy alejados del grueso de los datos; después se decide corregirlos, quitarlos o conservarlos.

¿Por qué SIEMPRE hay que visualizar?

El **cuarteto de Anscombe** (y el “Datasaurus”) son conjuntos de datos con **las mismas estadísticas** – igual media, varianza, correlación y recta de regresión – pero formas **completamente distintas**.

Moraleja

Las estadísticas resumen, pero pueden ocultar la realidad. Una gráfica revela patrones, outliers y errores que los números esconden.



SECCION

Etapa 05: Archivado y eliminación

Archivado y eliminación: definición y errores

Definición

Almacenamiento de larga estancia para datos inactivos, o eliminación cuando ya no se necesitan.

¿Cuándo archivar?

Cuando los datos están inactivos pero aún se necesitan para cumplimiento o análisis histórico.

Posibles errores

- Archivado inaccesible.
- Eliminación de datos por error.
- Incumplimiento de regulaciones.

Buenas prácticas y herramientas de archivado

Mejores prácticas

- Mover a almacenamiento **frío** (Glacier, Azure Blob Archive).
- Comprimir y cifrar antes de archivar.
- Documentar metadatos (fecha, responsable, razón).
- Automatizar el proceso.

Herramienta	Tipo	Uso típico
AWS Glacier	Cloud	Archivado masivo en nube
MinIO	On-prem	Reemplazo de S3 on-premise
Veritas E. Vault	On-prem	Corporativo con cumplimiento
Archivematica	On-prem	Preservación a largo plazo
PostgreSQL part.	On-prem	Tablas muy grandes

Cumplimiento legal y derechos ARCO

Regulaciones clave

- **GDPR:** derecho al olvido (Art. 17).
- **CCPA:** eliminación bajo solicitud.
- **HIPAA:** retención de registros médicos.

Documentar **todo**: cuándo, cómo y por qué se archivaron o eliminaron los datos (auditoría).

Derechos ARCO

- **Acceso:** saber qué datos hay sobre mí.
- **Rectificación:** corregir datos inexactos.
- **Cancelación:** eliminar datos que ya no se necesitan.
- **Oposición:** negarse a cierto uso (p.ej. publicidad).

Clasificación de datos

Antes de archivar o eliminar conviene **clasificar** los datos:

- **Sensibilidad:** personales, financieros, de salud.
- **Frecuencia de uso:** activos, inactivos, históricos.
- **Requisitos legales:** tiempos de retención obligatorios.

Herramientas de etiquetado (a menudo automatico): Apache Ranger, AWS Macie, OpenDLP, Microsoft Presidio.

SECCION

Resumen

Takeaways

- **Seguridad (03)**: cifrar en reposo y en tránsito, usar consultas parametrizadas y **mínimos privilegios** (RBAC); la IA es a la vez amenaza (deepfakes, data poisoning) y defensa.
- **Análisis (04)**: el **EDA** describe, limpia faltantes, detecta outliers (IQR) y mide correlaciones.
- **Visualizar siempre**: Anscombe muestra que las mismas estadísticas pueden esconder formas muy distintas.
- **Archivado (05)**: almacenamiento frío, comprimir/cifrar y documentar metadatos; eliminar cumpliendo **GDPR/ARCO**.
- Clasificar los datos por sensibilidad guía cómo protegerlos, archivarlos y eliminarlos.

Gracias

El ciclo de vida completo: de la captura a la eliminación