

Clase 05 – Cultura de datos

Gramatica compartida, correlacion vs causalidad y como no mentir con estadísticas

Instituto Tecnológico Jose Mario Molina Pasquel y Henriquez
22 de julio de 2026

Agenda

Que es cultura de datos

Gramatica compartida: humanos vs maquinas

Correlacion no es causalidad

Como mentir con estadisticas

Resumen

SECCION

Que es cultura de datos

Mas alla de las herramientas

Tener bases de datos, dashboards o modelos de IA no es lo mismo que tener **cultura de datos**.

Cultura de datos

El conjunto de **habitos, valores y habilidades** con los que una organizacion (o una persona) **crea, comparte y usa** datos para tomar decisiones.

Tres sintomas de que falta cultura de datos:

- Cada equipo nombra y formatea los datos distinto (falta de gramatica compartida).
- Se confunde “estan correlacionados” con “uno causa al otro”.
- Una grafica o un promedio mal elegido convence sin que nadie pregunte como se calculo.

SECCION

Gramatica compartida: humanos vs maquinas

Una gramatica, dos lectores

Ya vimos la gramatica de los datos (tipos, estructura, formato tidy) y la diferencia entre datos para **humanos** y para **maquinas**.

El punto de cultura de datos

Una organizacion con cultura de datos madura acuerda **una** gramatica -nombres de columnas, unidades, formatos de fecha, codigos- y la respeta en todos sus sistemas y equipos, para personas **y** para maquinas.

El mismo dato, dos presentaciones

Para humano (tabla legible)

Region	Ventas
Monterrey	\$320,000

Fecha: “22 de julio de 2026”. Legible, redondeado, en lenguaje natural.

Para maquina (JSON + esquema)

```
{ "region": "MTY",  
  "ventas": 320000,  
  "unidad": "MXN",  
  "periodo": "2026-Q1"}  
# esquema: region:str, ventas:int(MXN),  
#           periodo:str(ISO 8601)
```

Tipado, con claves normalizadas y metadatos.

Cuando la gramatica falla

Una gramatica de datos deficiente rompe **ambas** lecturas a la vez:

- Columnas ambiguas: ¿fecha? ¿de captura, de venta, de entrega?
- Formatos inconsistentes: “22/07/2026”, “2026-07-22” y “jul-22-26” en la misma columna.
- Texto libre mezclado con codigos: “Monterrey (MTY)” en una celda que a veces solo trae “MTY”.

Esto no es un problema tecnico aislado: es un **sintoma de falta de cultura de datos** en la organizacion.

SECCION

Correlacion no es causalidad

Dos variables que se mueven juntas


Que dos variables **correlacionen** no significa que una **cause** a la otra. Puede deberse a:

- **Azar**: con suficientes series, algo correlaciona con algo.
- **Variable confusora**: una tercera variable oculta mueve a ambas.
- **Causalidad inversa**: creemos que A causa B, y es B quien causa A.

Regla de cultura de datos

Antes de publicar una conclusion causal, pregunta: ¿hay una tercera variable que explique ambas?

Ejemplo 1: helados y ahogamientos



Ambas suben en verano. La variable oculta es la **temperatura**, no que el helado cause ahogamientos.

Mas ejemplos clasicos

- **Ciguenas y natalidad:** en algunas regiones de Europa, mas ciguenas correlaciona con mas nacimientos. Variable oculta: ruralidad / tamaño de la población.
- **Zapato y lectura:** el tamaño del zapato de un niño correlaciona con su habilidad de lectura. Variable oculta: **la edad**.
- **Correlaciones espurias** (Tyler Vigen): consumo de queso mozzarella per capita vs. doctorados en ingeniería civil en EE.UU. Con suficientes series de tiempo, siempre aparecen correlaciones altas sin ningún vínculo causal.

¿Entonces como se prueba causalidad?

Observar correlacion en datos historicos **no basta**. Se necesita:

- **Experimentos controlados / aleatorizados**: asignar el tratamiento al azar y comparar grupos.
- **Metodos de inferencia causal**: cuando el experimento no es posible (variables instrumentales, diseno de discontinuidad, etc.).

Sin uno de estos disenos, lo mas honesto es decir “correlacionan”, no “uno causa al otro”.

SECCION

Como mentir con estadísticas

Un libro clasico (Darrell Huff, 1954)

Como mentir con estadisticas explica como graficas y estadisticas mal usadas -intencional o no- distorsionan la percepcion.

Por que importa para la cultura de datos

Exige **escepticismo** y **alfabetizacion estadistica** tanto en quien produce los datos como en quien los consume.

La muestra con sesgo incorporado

Una encuesta por correo o por telefono solo llega a cierto grupo socioeconomico, pero se presenta como si representara a **toda** la poblacion.

- ¿Quien responde encuestas largas o llamadas de numeros desconocidos?
- El resultado esta sesgado desde el diseno de la muestra, no en el analisis posterior.



El promedio bien elegido

Media, mediana y moda cuentan historias distintas. Se elige la que **favorece el argumento**.

Ejemplo

Una empresa anuncia un “salario promedio” (**media**) inflado por los sueldos de unos pocos directivos. La **mediana** da un cuadro mas realista del empleado tipico.

La grafica que impresiona (gee-whiz graph)



El mismo cambio de **3 %** se ve plano en un eje que empieza en cero, y se ve como un crecimiento enorme si el eje se trunca cerca del valor real.

Mas trucos del libro

- **Pictogramas engañosos:** para representar “el doble” se duplica alto y ancho de un icono, y el area se ve 4 veces mayor en vez de 2.
- **Post Hoc Rides Again:** el capitulo del libro dedicado justamente a correlacion vs causalidad -el mismo tema de la seccion anterior.
- **Cifras semi-adjuntas:** responder una pregunta distinta a la que se hizo. “9 de cada 10 dentistas recomiendan...” sin aclarar la pregunta exacta ni el tamaño de la muestra.

No es para manipular, es para reconocerlo

El objetivo de estudiar estas trampas **no** es aprender a manipular:

- Como **consumidores** de datos, reconocerlas para no dejarnos convencer por una grafica o un promedio sin preguntar como se calculo.
- Como **productores** de datos, evitarlas: mostrar el eje completo, elegir el promedio adecuado, aclarar la pregunta y la muestra.

Esa doble postura -escepticismo al leer, honestidad al producir- es la **cultura de datos** que buscamos.

SECCION

Resumen

Takeaways

- La cultura de datos son los **habitos, valores y habilidades** para crear, compartir y usar datos al decidir.
- Una **gramatica compartida** (nombres, unidades, formatos) sirve tanto a personas como a maquinas; sin ella, ambas lecturas se rompen.
- **Correlacion no es causalidad**: revisa variables confusoras antes de concluir causa y efecto.
- *Como mentir con estadisticas*: muestra sesgada, promedio bien elegido, ejes truncados, pictogramas y cifras semi-adjuntas son trampas a reconocer y a evitar.
- Cultura de datos = escepticismo al consumir + honestidad al producir.

Gracias

Datos con cultura: gramática clara, causas verificadas