


01 Creación y captura
Generación u obtención de datos (sensores, formularios, transacciones, APIs, etc.).

02 Transmisión y almacenamiento
Los datos se envían a bases de datos, lago de datos, datawarehouse,



05 Archivado/ Eliminación

Almacenamiento de larga estancia o se borran

04 Limpieza, Uso, Análisis y Visualizaciones

Los datos se depuran y se procesan para calcular, analizar o visualizar algo.

03 Gestión de acceso y seguridad

Los datos se comparten con otros usuarios y fluyen a otras aplicaciones

El ciclo de vida de los datos describe las fases por las que pasan desde su creación hasta su eliminación o archivado

01 Creación y Captura

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

01 Creación y captura

Generación u obtención de datos (sensores, formularios, transacciones, APIs, etc.).



Posibles errores:

- Datos incompletos (campos vacíos).
- Datos duplicados.
- Errores de formato (ej: fecha en texto "12/31/2024" vs. "31-12-2024").
- Sesgo en la recolección (muestras no representativas).
- Diferente formato UTF-8



01 Creación y captura: Censo

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

01 Creación y captura

Generación u obtención de datos (sensores, formularios, transacciones, APIs, etc.).

01

Retos:

- **Alto costo** (requiere recursos humanos, logística y tiempo).
- **Cobertura completa** (dificultad para llegar a zonas remotas o poblaciones móviles).
- **Actualización** (los datos pueden quedar obsoletos rápidamente).
- **Participación** (resistencia de algunos grupos a proporcionar información).

Censo

- Recopilación sistemática de datos de **toda la población** de interés (no sólo una muestra).
- Busca **datos** exhaustivos y completos
- [Una operación estadística para recopilar, procesar y difundir datos sobre la estructura de la agricultura, cubriendo la totalidad o una parte significativa de un país.](#)
- La metodología determina el nivel de confianza y error



Censo

1. Definir Objetivos y Alcance

- **Propósito/Tema:** ¿Para qué se realiza el censo?
- **Población objetivo:** ¿Quiénes serán censados?
- **Cobertura geográfica:** Nacional, regional o local.

2. Marco Legal y Financiamiento

- **Base legal:** Leyes o decretos que autorizan el censo.
- **Presupuesto:** Estimación de costos (personal, tecnología, logística).

3. Diseño Metodológico

- **Variables a medir:** Definir qué datos se recolectarán (ej. edad, ingresos, tipo de vivienda).
- **Instrumentos:** Cuestionarios (papel/digital), formularios, guías para encuestadores.
- **Periodo de referencia:** Fecha específica para los datos

4. Pruebas Piloto

- **Censo experimental:** Aplicar el cuestionario en una zona pequeña para detectar errores.
- **Ajustes:** Corregir preguntas ambiguas, tiempos de recolección o logística.

5. Cartografía y Segmentación

- **División territorial:** Crear mapas detallados con áreas de cobertura
Actualización: Verificar cambios en límites geográficos o viviendas.

6. Capacitación de Personal

- **Reclutamiento** y selección Seleccionar y entrenar personal.
- **Protocolos:** Enseñar técnicas de entrevista, manejo de datos y ética.

7. Recolección de Datos

- **Modalidades:****Presencial:** Visita casa por casa. **Autodiligenciamiento:** Formularios físicos (con seguimiento).
- **Monitoreo:** Supervisar avances y resolver problemas en campo.

8. Procesamiento y Validación

- **Digitación:** Ingreso de datos a sistemas informáticos.
- **Depuración:** Identificar y corregir inconsistencias.

9. Análisis, difusión y evaluación

- **Resultados preliminares:** Cifras básicas (población total por región).
- **Informes finales:** Publicación detallada con tabulados y análisis.
- **Plataformas de acceso:** Bases de datos públicas o interactivas.
- **Calidad:** Medir subregistro o errores
- Documentar fallas para mejorar futuros censos.

Año 1116

El rey Xólotl ordena censar a sus súbditos que llegaron a orillas del lago de Texcoco.

Entre 1790 y 1793

El Censo de Revillagigedo recopiló información sobre población, edad, estado civil, casta, ocupación, entre otros.

1831 - 1832

- En 1831 se ordena el levantamiento del Censo General de la República.
- En 1832 se corrige y publica como el Censo de Valdés.

1895

Se levanta el Primer Censo General de Población.

Entre 1900 y 1921

- 1900. Segundo Censo General de Población.
- 1910. Censo de Población de los Estados Unidos Mexicanos.
- 1921. Censo General de Habitantes.

1930 - 1980

- 1930 a 1970. Se levantan del V al IX Censo General de Población.
- 1980. X Censo General de Población y Vivienda.

1980 - 1983

- En 1980 se publica la Ley de Información Estadística y Geográfica.
- En 1983 se crea el INEGI.

Entre 1990 y 2010

- 1990, 2000 y 2010. Levantamiento de rondas censales.
- 1995 y 2005. Primer y segundo conteo de Población y Vivienda.



126,014,024
personas en
México

IEG
Instituto de Información

Censo de Población y Vivienda	Censos Económicos	Censo Agropecuario	Censos de Gobierno
es útil para...	son útiles para...	es útil para...	son útiles para...
Conocer cuántas viviendas hay en el país, cuántos habitantes hay, su edad, sexo y cómo se distribuyen en el territorio nacional, entre otros datos.	Conocer la información de todos los establecimientos y empresas del país: qué, cuánto, quién, dónde, cómo y con qué se produce.	Conocer las actividades agrícolas, ganaderas y forestales del país: como la superficie dónde se llevan a cabo, qué se cultiva, qué animales se tiene, entre otra información.	Conocer la situación y el desempeño de las instituciones públicas de los 3 niveles de gobierno: federal, estatal y municipal.
se realiza:	se realizan:	se realiza:	se realizan:
cada 10 años*	cada 5 años	cada 10 años	cada año y cada dos años**



Encuesta

01 Creación y captura

Generación u obtención de datos (sensores, formularios, transacciones, APIs, etc.).

01

Retos:

- **Diseño del cuestionario** (preguntas ambiguas o sesgadas).
- **Tasa de respuesta** (no respuesta o abandono).
- **Sesgos** (deseabilidad social, errores de memoria).
- **Costos en muestras grandes** (vivienda)

Encuesta

- Recolección de datos mediante cuestionarios estructurados aplicados a una **muestra representativa** de la población para inferir que *piensa* la población.
- Método de recopilación de datos
- Herramienta de recolección de información de una muestra representativa.
- Tenemos que saber información de la distribución.
- Muestra aleatorio.
- Se buscan tendencias generales.
- El margen de error es aceptable.
- El tiempo y recursos son limitados.

Nivel de confianza del 95%

Margen de error más o menos 3%



Encuesta

01 Creación y captura

Generación u obtención de datos (sensores, formularios, transacciones, APIs, etc.).

01

Retos:

- **Diseño del cuestionario** (preguntas ambiguas o sesgadas).
- **Tasa de respuesta** (no respuesta o abandono).
- **Sesgos** (deseabilidad social, errores de memoria).
- **Costos en muestras grandes** (vivienda)

Encuesta

- Recolección de datos mediante cuestionarios estructurados aplicados a una **muestra representativa** de la población para inferir que *piensa* la población.
- Método de recopilación de datos
- Herramienta de recolección de información de una muestra representativa.
- Tenemos que saber información de la distribución.
- Muestra aleatorio.
- Se buscan tendencias generales.
- El margen de error es aceptable.
- El tiempo y recursos son limitados.

Nivel de confianza del 95%

Margen de error más o menos 3% (tamaño población)



Encuesta

01 Creación y captura

Generación u obtención de datos (sensores, formularios, transacciones, APIs, etc.).

01

Retos:

- **Diseño del cuestionario** (preguntas ambiguas o sesgadas).
- **Tasa de respuesta** (no respuesta o abandono).
- **Sesgos** (deseabilidad social, errores de memoria).
- **Costos en muestras grandes** (vivienda)

Encuesta

- Recolección de datos mediante cuestionarios estructurados aplicados a una **muestra representativa** de la población para inferir que *piensa* la población.
- Método de recopilación de datos
- Herramienta de recolección de información de una muestra representativa.
- Tenemos que saber información de la distribución.
- Muestra aleatorio.
- Se buscan tendencias generales.
- El margen de error es aceptable.
- El tiempo y recursos son limitados.

Nivel de confianza del 95%

Si se repitiera el estudio **100 veces**, en **95 de ellas** los resultados caerían dentro del **margen de error** establecido.

No garantiza que el resultado sea exacto, sino que hay un 95% de probabilidad de que la realidad esté cerca de lo medido.



01 Creación y captura: Sondeo

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

01 Creación y captura

Generación u obtención de datos (sensores, formularios, transacciones, APIs, etc.).

01

Retos:

- **Sesgo de selección** (la muestra puede no ser representativa).
- **Poca profundidad** (datos superficiales).
- **Validez limitada** (resultados no generalizables).

Sondeo

- Método rápido y **no exhaustivo** para obtener información preliminar, usualmente con una muestra pequeña o informal.
- Rápidos y enfocados en obtener una visión general.
- Tienen más errores y sesgos que un censo y una encuesta.
- Los usuarios deciden si participar.
- Sus resultados no son generalizables.



administrativos

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

01 Creación y captura

Generación u obtención de datos (sensores, formularios, transacciones, APIs, etc.).

01

Retos:

- **Calidad inconsistente** (errores en registros).
- **Acceso restringido** (privacidad, burocracia).

Datos administrativos

- Información recolectada para fines no estadísticos
- Registros salud, impuestos
- Procesos internos.



Sensores

01 Creación y captura

Generación u obtención de datos (sensores, formularios, transacciones, APIs, etc.).

01

Retos:

- **Costo**
- **Acceso restringido** (privacidad,

Sensores

- Datos medidos de forma directa e indirecta
- Monitoreo



Levantamiento en campo

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

01 Creación y captura

Generación u obtención de datos (sensores, formularios, transacciones, APIs, etc.).

01

Levantamiento en campo

- Recolección de datos **in situ**, mediante observación directa, mediciones o entrevistas en terreno

Retos:

- **Accesibilidad** (terrenos difíciles o peligrosos).
- **Precisión** (errores humanos en medición o registro).
- **Condiciones ambientales** (clima, fauna).
- **Logística compleja** (equipos, permisos).



de datos

01 Creación y captura

Generación u obtención de datos (sensores, formularios, transacciones, APIs, etc.).

01

Minería de datos


- Análisis de grandes volúmenes de datos generados digitalmente (redes sociales, transacciones).

Retos:

- Privacidad
- Ruido de datos.




data that will not fit
in main memory.



Big data: extremely **large** and **diverse** collections of structured, unstructured, and semi-structured data that **continues to grow** exponentially over time. These datasets are complex in **volume**, **velocity**, and **variety**, that **traditional data management systems cannot store, process, and analyze** them.

Techniques: Mapreduce, parallel computing and sampling





**Data that will not fit
in main memory.**

**Data with a large
number of observations
and/or features (statistics)**

non-traditional sample size

**One of the main challenges of big data is the
ability to
store, process, and analyze it effectively**

Goal: Generalizations

A model or summarization of the data.

**Focus on scalability and algorithms/analyses
not possible without large data.**



5 V's OF DATA



VOLUME

Amount of Data



VARIETY

Diversity of Data



VELOCITY

Speed of
Data Generation



VALUE

Worth of Data



VERACITY

Accuracy of Data



56V of Big data

V's Characteristics

1. Volume
2. Variety
3. Velocity
4. Veracity
5. Validity
6. Value
7. Variability
8. Venue
9. Vocabulary
10. Vagueness
11. Vulnerability

12. Volatility
13. Visualization
14. Viscosity
15. Virality
16. Virtual
17. Valence
18. Viability
19. Virility
20. Vendible
21. Vanity
22. Voracity

23. Visible
24. Visual
25. Vitality
26. Vincularity
27. Verification
28. Valor
29. Verbosity
30. Versality
31. Veritable
32. Violable
33. Varnish

34. Vogue
35. Vault
36. Voodoo
37. Veil
38. Vulpine
39. Verdict
40. Vet
41. Vane
42. Vanillal
43. Victual
44. Vantage

34. **Vogue** Artificial intelligence are become? [1] [16].
35. **Vault** Importance of data security [1] [16].
36. **Voodoo** Deliver results with real-world impact [1] [16].
37. **Veil** Examine latent variables from behind the curtain [1] [16].

51. Voyage
52. Varifocal
53. Version
control
54. Vexed
55. Vibrant
56. Vogue

19. **Virility**

With Big Data it means that it creates itself. The more Big Data you have, the more Big Data gets strength and forceful [1] [7] [8] [9] [10].





2008



2011



2012



2010



2011



2018



Estados Unidos: [Data.gov](https://data.gov) (clima, salud, educación, transporte, etc.).

Unión Europea: [European Data Portal](https://european-data-portal.eu).

Francia: data.gouv.fr (transportes, medio ambiente, economía, entre otros).

India: data.gov.in.

Reino Unido: data.gov.uk.

NASA: [Open Data Portal](https://open.data.nasa.gov) (datos espaciales, imágenes satelitales, etc.).

NOAA: National Centers for Environmental Information (clima, océanos, atmósfera).

European Space Agency: Copernicus Open Access Hub (imágenes satelitales).

Kaggle Datasets: Kaggle

DrivenData: drivendata.org

<https://datos.gob.mx/> iiieg.gob.mx





<https://pdfcoffee.com/la-maquina-que-gano-la-guerra-isaac-asimov-pdf-free.html>

Datos y su importancia II

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

—Claro —dijo Swift con ánimo consolador—. Comprendo que lo intentarás. En esta ocasión Jablonsky decidió encender su cigarrillo.

—No obstante, supongo que suministraste datos a los programas de Multivac. No nos dijiste nada sobre esa confiabilidad.

—¿Cómo podía decíroslo? Y si lo hubiera hecho, ¿cómo asegurarme de que ibais a creerme? —preguntó Henderson salvajemente—. El esfuerzo total de la guerra recaía sobre Multivac. Era nuestra única gran arma, pues los denebianos no tenían nada igual. ¿Qué otra cosa podría elevar más la moral que la seguridad de saber que Multivac estaría siempre prediciendo y cercando cualquier movimiento denebiano y que dirigiría siempre y siempre prevería la infalibilidad de nuestras propias maniobras? Por el Gran Espacio, desde que nuestra red de espionaje fue arrojada del hiperespacio no pudimos ya obtener ningún dato fiable acerca de los denebianos para seguir alimentando Multivac, y eso era algo que no podíamos arriesgarnos a hacer público.



Ciclo de vida de los datos:02

El Instituto de Información
Estadística y Geografía
de Jalisco

02 Transmisión y almacenamiento

Los datos se envían a bases
de datos, lago de datos,
datawarehouse,



Posibles errores:

- Pérdida de datos por fallos de hardware.
- Almacenamiento redundante (duplicidad).
- Duplicidad
- Estructura inadecuada (ej: tablas mal normalizadas en SQL).
- **Sin respaldo Regla 3-2-1 o sin respaldos periódicos.**
- **Corrupción de datos.**
- **Errores en el ETL**
- **Formatos incompatibles**


3-2-1: mantener **tres** copias de los
datos, en **dos** tipos diferentes de
medios de almacenamiento, y **una**
copia fuera del sitio



Ciclo de vida de los datos:02

02 Transmisión y almacenamiento

Los datos se envían a bases
de datos, lago de datos,
datawarehouse,



ETL

- **Extracción-Transformación-Carga**
- ETL = Extract -> Transform -> Load

– **Extract:** Obtener los datos tan eficientemente como sea posible

– **Transform:** hacer algunos cálculos, transforman los datos, limpiar datos

– **Load:** cargar los datos en la siguiente aplicación

Plomero de los datos: Los datos se mueven desde las fuentes a los siguientes procesos.

Ciclo de vida de los datos:02

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

02 Transmisión y almacenamiento

Los datos se envían a bases
de datos, lago de datos,
datawarehouse,

02

Data Lake

Un **Data Lake** es un repositorio que almacena datos **en bruto** (estructurados, semiestructurados y no estructurados) sin procesar inicialmente.

Datos en crudo: Sin transformar (JSON, CSV, imágenes, logs, etc.).

Esquema flexible: No requiere estructura definida al ingresar.

Big Data: Usado para análisis masivo con operaciones simples por ejemplo map reduce.

Escalable: Diseñado para grandes volúmenes (Hadoop, AWS S3).



Ciclo de vida de los datos:02

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

02 Transmisión y almacenamiento

Los datos se envían a bases
de datos, lago de datos,
datawarehouse,

02

Datawarehouse (Almacén de datos)

Es un repositorio centralizado de datos estructurados y procesados, diseñado para **consultas y análisis empresarial**

Características

Datos estructurados: Organizados en tablas (esquema relacional).

Procesados (ETL): Los datos se limpian, transforman y cargan antes de almacenarse.

Orientado a consultas: Optimizado para reportes y análisis

Input datos estructurados




Ciclo de vida de los datos:02

IIIG


Data Warehouse



Data Lake



Data Lakehouse



Data Warehouse Vs Data Lake


IEG
Instituto de Información
Estadística y Geográfica
de Jalisco

Aspecto	Data Warehouse	Data Lake
Tipo de datos	Sólo estructurados (tablas SQL).	Cualquier tipo (JSON, imágenes, logs).
Procesamiento	Datos transformados antes de almacenar (ETL).	Datos en crudo (se procesan al leer).
Esquema	Definido antes de cargar (schema-on-write).	Definido al consultar (schema-on-read).
Usuarios	Analistas de BI.	Científicos de datos/Ingenieros.
Herramientas	Snowflake, Redshift, BigQuery.	Hadoop, AWS S3, Azure Data Lake.




Orquestación de datos

La orquestación de datos es el proceso de extraer datos aislados de múltiples ubicaciones de almacenamiento, combinarlos, organizarlos y ponerlos a disposición de las herramientas de análisis de datos. También puede incluir tareas como el aprovisionamiento de recursos y la monitorización.



<https://airflowsummit.org/slides/2022/b1-choosing-airflow-v2.pdf>



History

Apache Airflow

- Started in October 2014 by Maxime Beauchemin at Airbnb.
- Open source from the very first commit and officially brought under the Airbnb GitHub and announced in June 2015
- Joined the Apache Software Foundation's Incubator program in March 2016

Broadcom AutoSys

- First developed by William Arntz and Walter Goodwin who created AutoSystems Ltd.
- Sold to Platinum Technology International in 1995
- Bought by Computer Associates in 1999
- Broadcom acquired CA in 2018 and known today as "AutoSys Workload Automation"

bmc Control-M

- Originally developed for scheduling jobs on mainframe computer systems, by an Israel-based company - New Dimension Software
- BMC software acquired New Dimension Software in **1999**
- "BMC Helix Control-M" - SaaS solution was released in December - **2020**

Spotify Luigi


- Created by Spotify mainly by Erik Bernhardsson and Elias Freider
- Initial commit on github/spotify/luigi on Nov 17, **2011**
- Open sourced in **2012**
- Spotify's Data Team maintains Luigi

<https://airflowsummit.org/slides/2022/b1-choosing-airflow-v2.pdf>


Ciclo de vida de los datos:02

IIEG
Instituto de Información
tica y Geográfica
co


Data Warehouse Architecture



Data Pipeline




<https://airflowsummit.org/slides/2022/b1-choosing-airflow-v2.pdf>




"Scripting + Cron would do!"

TFX

**TFX es una
plataforma de
extremo a extremo
para implementar
canalizaciones de
producción de AA**





<https://airflowsummit.org/slides/2022/b1-choosing-airflow-v2.pdf>

Definiciones básicas


- **Apache Airflow:**
 - Plataforma de **orquestación de workflows** programables.
 - Open-source, escrito en Python.
- Características clave:
 - Escalable, dinámico, extensible.
 - Basado en **DAGs** (*Directed Acyclic Graphs*).
- Ejemplos comunes:
 - ETL/ELT (Data Pipelines).
 - Entrenamiento de modelos de ML.
 - Automatización de reportes.
 - Orquestación de tareas en la nube (AWS, GCP, Azure).

Estructura del Airflow

- **DAG**: Grafo acíclico dirigido (conjunto de tareas ordenadas).
- **Operators**: Bloques de construcción (PythonOperator, BashOperator, etc.).
- **Tasks**: Instancias de un Operator.
- **Scheduler**: Ejecuta tareas según dependencias.
- **Executor**: Define cómo se ejecutan las tareas (LocalExecutor, CeleryExecutor).

Laboratorio Colab

<https://colab.research.google.com/drive/1MKcGODLRthj9Hximu6W7VEiWWBVz91TU?usp=sharing>



Ciclo de vida de los datos

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

Posibles errores:

- Robo/secuestro de datos
- Datos inaccesibles
- Formatos obsoletos
- Riesgos legales
- Falta de encriptación o anonimización
- No cumplir con estándares.

03

03 Gestión de acceso y seguridad

Los datos se comparten con otros usuarios y fluyen a otras aplicaciones



Ciberseguridad

- Protección y seguridad de sistemas y datos contra ataques digitales.
- Son un conjunto de prácticas y principios diseñadas para salvaguardar la infraestructura e información en contras de ataques.




THE WHY

Critical Cyber Workforce Shortage

Our national security and economic stability depends on us solving it.

- Employers are desperate for cyber degree program graduates.³
- **504,316 cybersecurity job vacancies** (Oct. 2018- Sep. 2019)¹, and the shortage continues to grow²
- Cybercriminals now responsible for **billions in losses per year** and **state-sponsored hacking groups** posing an ever-greater threat.³

Cybersecurity Supply/Demand Heat Map
Total Job Openings




¹ CyberSeek.org
² Supporting the Growth and Sustainment of the Nation's Cybersecurity Workforce. https://www.nist.gov/sites/default/files/documents/2018/07/24/eo_wf_report_to_potus.pdf
³ The Cybersecurity Workforce Gap. William Crumpler & James A. Lewis. https://csis-prod.s3.amazonaws.com/s3fs-public/publication/190129_Crumpler_Cybersecurity_FINAL.pdf

The number of cyber security buyers has doubled since FY18-19

In 4 years, the number of contracting authorities awarding cyber-security contracts almost **doubled from 168 to 327**

There is still plenty of room for growth – in FY22-23 this was **only 16%** of all UK public sector contracting authorities

Volume of contracting authorities awarding cyber-security contracts, FY18-19 - FY22-23



tussell*



AI IN CYBERSECURITY



1

Social engineering schemes:

These schemes rely on psychological manipulation to trick individuals into revealing sensitive information or making other security mistakes. They include a broad range of fraudulent activity categories, including phishing, vishing and business email compromise scams.



2

Password hacking:

Cybercriminals exploit AI to improve the algorithms they use for deciphering [passwords](#). The enhanced algorithms provide quicker and more accurate password guessing, which allows hackers to become more efficient and profitable. This may lead to an even greater emphasis on password hacking by cybercriminals.



3

Deepfakes:

This type of deception leverages AI's ability to easily manipulate visual or audio content and make it seem legitimate. This includes using phony audio and video to impersonate another individual. The doctored content can then be broadly distributed online in seconds—including on influential social media platforms—to create stress, fear or confusion among those who consume it.



4

Data poisoning:

Hackers “poison” or alter the training data used by an AI algorithm to influence the decisions it ultimately makes. In short, the algorithm is being fed with deceptive information, and bad input leads to bad output.



Inyección SQL

- **Qué es:** Ataque donde se inserta código malicioso en consultas SQL
- **Impacto:** Robo, modificación o eliminación de datos.
- **Mitigación:**
 - Usar consultas parametrizadas (prepared statements).
 - Validar y sanitizar inputs.

Exposición de Datos Sensibles

- **Qué es:** Acceso no autorizado a datos por falta de encriptación o permisos excesivos.
- **Mitigación:**
 - Encriptar datos en reposo (AES-256) y en tránsito (TLS).
 - Implementar **mínimos privilegios** (RBAC).

RBAC (*Role-Based Access Control*)

Configuraciones Inseguras

- **Ejemplos:** Credenciales por defecto, puertos abiertos (ej: 3306 para MySQL).
- **Solución:**
 - Hardening de la base de datos (deshabilitar servicios innecesarios).

4. Falta de Backup Seguro

- **Riesgo:** Pérdida de datos por ransomware o fallos.
- **Mitigación:**
 - Backups automáticos + encriptados.
 - Probarlos regularmente.



Riesgo	Bases de Datos	Procesos ETL
Inyección	SQL Injection	Inyección en transformaciones
Exposición	Datos en reposo	Datos en tránsito
Autenticación	Privilegios excesivos	Credenciales en código
Integridad	Corrupción de datos	Datos no validados



Taller de datos

- Acomodar los datos, nombres de columna eliminar encabezados, imágenes(Casi dejar como CSV)
- Explorar:
 - Buscar los datos faltantes (reemplazarlos, eliminarlos),
 - Describir los tipos de datos y en su caso transformarlos por ejemplo enteros, o fechas.
 - Visualizar los datos.
 - Resolver problemas.



Ciclo de vida de los datos

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

Posibles errores:


- Uso de datos desactualizados
- Interpretación incorrecta
- Falta de revisión de los procedimientos

04

04 Limpieza, Uso, Análisis y Visualizaciones


Los datos se depuran y se procesan para calcular, analizar o visualizar algo.





EDA

Exploratory Data Analysis




Data distribution

	F	G	H	I	J
A	0.620576	0.140053	1.352728	NaN	0.808078
B	NaN	0.526829	NaN	NaN	0.170902
C	NaN	0.458827	1.406713	0.071119	NaN
D	NaN	2.307197	NaN	NaN	NaN
E	0.203402	0.259913	NaN	0.505811	1.516755


Missing data



Outliers




Correlation



Patterns

```
Cust_No      int64
Cust_Name    object
Product_id   int64
Product_cost float64
Purchase_Date datetime64[ns]
dtype: object
```



Data types

Data visualization

Data quality

1. Distribution Analysis

Distribution analysis is a fundamental technique used in EDA. It helps us understand how the data points in our dataset are distributed across its range. It also helps in identifying any outliers and is often represented using histograms, density plots, and box plots.

2. Correlation Analysis

Correlation analysis helps to identify the relationships between various variables in our dataset. Understanding these dependencies is an important concept in machine learning, as it allows the selection of relevant predictors for your model and avoids multicollinearity.

3. Outlier Detection

Effective outlier detection is a crucial phase in exploratory data analysis. Using tools such as box plots or scatter plots can help recognize anomalies in your data. Predictive modeling greatly benefits from a clean dataset, free of outliers. Specialized algorithms for outlier detection can be incorporated into your analysis process for further refinement and optimization.

4. Multivariate Analysis

Multivariate data analysis is a crucial aspect of exploratory data analysis. It utilizes statistical methods to help decipher patterns or relationships between multiple data



EDA

Exploratory Data Analysis




Data distribution

	F	G	H	I	J
A	0.620576	0.140053	1.352728	NaN	0.808078
B	NaN	0.526829	NaN	NaN	0.170902
C	NaN	0.458827	1.406713	0.071119	NaN
D	NaN	2.307197	NaN	NaN	NaN
E	0.203402	0.259913	NaN	0.505811	1.516755


Missing data



Outliers




Correlation



Patterns

```
Cust_No      int64
Cust_Name    object
Product_id   int64
Product_cost float64
Purchase_Date datetime64[ns]
dtype: object
```

Data types



Data visualization



Data quality

4. Multivariate Analysis

Multivariate data analysis is a crucial aspect of exploratory data analysis. It utilizes statistical methods to help decipher patterns or relationships between multiple data variables simultaneously. This technique offers a profound insight into the dataset, helping knowledge workers make informed decisions.


5. Time Series Visualization


Decoding patterns and seasonal trends through time series visualization is a powerful component. With interactive tools, knowledge workers can visually examine fluctuations over a period, facilitating the recognition of anomalies and forecasting.

6. Dimensionality Reduction

To handle complex datasets with a large number of features, efficient dimensionality reduction techniques are critical. Techniques such as PCA and t-SNE offer effective ways to reduce data dimensionality, speeding up the learning process without losing important information.







<https://www.research.autodesk.com/publications/same-stats-different-graphs/>

Taller de datos

- Acomodar los datos, nombres de columna eliminar encabezados, imágenes(Casi dejar como CSV)
- Explorar:
 - Buscar los datos faltantes (reemplazarlos, eliminarlos),
 - Describir los tipos de datos y en su caso transformarlos por ejemplo enteros, o fechas.
 - Visualizar los datos.
 - Resolver problemas.



Ciclo de vida de los datos

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

Posibles errores:

- Archivado inaccesible
- Eliminación de datos por error
- Incumplimiento de regulaciones

05

05 Archivado/ Eliminación

Almacenamiento de larga estancia o se borran



Ciclo de vida de los datos

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

Clasificación

Clasificación de Datos

- **Categorizar por:**
 - **Sensibilidad** (datos personales, financieros, de salud).
 - **Frecuencia de uso** (activos, inactivos, históricos).
 - **Requisitos legales** (tiempos de retención obligatorios).
- **Herramientas:** Usar etiquetado automático

<https://colab.research.google.com/drive/1EJVRgHrCqQCVVIT4099WDx0Mg1V1Ktw-?usp=sharing>

05

05 Archivado/ Eliminación

Almacenamiento de larga estancia o se borran



Apache Ranger

AWS Macie



opendlp

<https://github.com/microsoft/presidio>



Ciclo de vida de los datos

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

Políticas de Archivado

- **¿Cuándo archivar?** Cuando los datos son inactivos pero aún necesarios para cumplimiento o análisis histórico.
- **Mejores prácticas:**
 - **Mover a almacenamiento frío** (ej: Amazon Glacier, Azure Blob Archive).
 - **Comprimir y cifrar** antes de archivar.
 - **Documentar metadatos** (fecha, responsable, razón del archivado).
 - **Automatizar procesos** con herramientas

05

05 Archivado/ Eliminación

Almacenamiento de larga estancia o se borran



Ciclo de vida de los datos

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

Herramienta	Tipo	Costo	Caso de Uso Típico
AWS Glacier	Cloud	Bajo (pago por uso)	Archivado masivo en la nube.
MinIO	On-Prem/Cloud	Open-Source	Reemplazo de S3 Glacier on-premise.
Veritas Enterprise Vault	On-Prem	Comercial	Archivado corporativo con cumplimiento.
Archivematica	On-Prem	Open-Source	Preservación digital a largo plazo.
PostgreSQL Partitioning	On-Prem	Open-Source	Archivado de tablas grandes.



Ciclo de vida de los datos

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

Cumplimiento Legal y Auditoría

- **Regulaciones clave:**
 - **GDPR:** Derecho al olvido (Art. 17).
 - **CCPA:** Eliminación de datos personales bajo solicitud.
 - **HIPAA:** Retención de registros médicos por 6 años.
 - **ARCO**
- **Documentar todo:** Mantener registros de cuándo, cómo y por qué se archivaron/eliminaron datos.
 -

05

05 Archivado/ Eliminación

Almacenamiento de larga estancia o se borran



Ciclo de vida de los datos

IIEG
Instituto de Información
Estadística y Geográfica
de Jalisco

1. **A – Acceso**

- Derecho a conocer qué datos personales están siendo procesados, para qué fines, y con quién se comparten.
- Ejemplo: Solicitar a un banco una copia de tus datos registrados.

2. **R – Rectificación**

- Derecho a corregir datos personales inexactos, incompletos o desactualizados.
- Ejemplo: Actualizar tu dirección en una plataforma de e-commerce.

3. **C – Cancelación (o Supresión)**

- Derecho a eliminar datos personales cuando ya no sean necesarios para los fines para los que fueron recopilados o cuando retires tu consentimiento.
- Ejemplo: Solicitar a una red social borrar tu cuenta y datos asociados.

4. **O – Oposición**

- Derecho a oponerse al tratamiento de tus datos para fines específicos (ej: publicidad, prospección comercial).
- Ejemplo: Negarse a recibir correos promocionales de una tienda.

05 Archivado/ Eliminación

Almacenamiento de larga estancia o se borran



04 Referencias

IIEG

Instituto de Información
Estadística y Geográfica
de Jalisco



Referencias y recomendaciones

<https://github.com/GeostatsGuy/DataScienceInteractivePython>

<https://dcai.csail.mit.edu/>

<https://www.datascience-pm.com/>

<https://microsoft.github.io/Data-Science-For-Beginners/#/>

<https://cognitiveclass.ai/>

<https://www.bbc.com/news/technology-54423988>

<https://sheetcast.com/articles/ten-memorable-excel-disasters>

